

Análise Multidimensional sobre Financiamento Público da Educação e Desempenho Escolar na Baixada Fluminense

Alekssander Santos¹, Vitória M. C. Chaves¹

¹Instituto de Computação – Universidade Federal do Rio de Janeiro (UFRJ)
Av. Athos da Silveira Ramos, 274 – Cidade Universitária, Rio de Janeiro – RJ, 21941-909
Orientador: Prof. Sergio Serra

{alekssanderscm,vitoriamcc}@ic.ufrj.br

Abstract. *This work describes the full trajectory of a data science project investigating whether public education funding (FUNDEB) explains student performance (ENEM) and higher-education access (SISU) in the 13 municipalities of Baixada Fluminense, Rio de Janeiro. We describe the pipeline end to end: ingestion and cleaning of three heterogeneous public microdata sources, a consolidated analytical dataset of 144,843 ENEM candidates and 1.3 million SISU applications (2013–2023), descriptive and inferential statistics, two predictive models (Ridge Regression and Random Forest), unsupervised clustering (K-Means) of municipal typologies, and a public Streamlit dashboard. The central finding is counter-intuitive: FUNDEB transfers are statistically significant ($p < 0,001$) but practically negligible predictors of individual scores ($\approx 8,5 \times 10^{-9}$ points per BRL), while household income and maternal education dominate. Three municipal clusters emerge, distinguishing efficient, over-funded/under-performing, and structurally vulnerable profiles. We conclude that closing the regional education gap requires management and equity policies, not merely larger nominal transfers.*

Resumo. *Este trabalho descreve a trajetória completa de um projeto de ciência de dados que investiga se o financiamento público da educação (FUNDEB) explica o desempenho escolar (ENEM) e o acesso ao ensino superior (SISU) nos 13 municípios da Baixada Fluminense (RJ). Descrevemos o pipeline de dados ponta a ponta: ingestão e limpeza de três bases públicas heterogêneas, um dataset analítico consolidado com 144.843 candidatos do ENEM e 1,3 milhão de inscrições no SISU (2013–2023), estatística descritiva e inferencial, dois modelos preditivos (Regressão Ridge e Random Forest), clusterização não supervisionada (K-Means) de tipologias municipais e um dashboard público em Streamlit. O achado central é contraintuitivo: o repasse do FUNDEB é estatisticamente significativo ($p < 0,001$), mas com efeito prático desprezível sobre a nota individual ($\approx 8,5 \times 10^{-9}$ pontos por real), enquanto renda familiar e escolaridade materna dominam a explicação. Emergem três clusters municipais que distinguem perfis eficientes, superinvestidos com desempenho mediano e estruturalmente vulneráveis. Concluímos que reduzir a desigualdade educacional regional exige políticas de gestão e equidade, não apenas maiores repasses nominais.*

1. Introdução

A Baixada Fluminense é uma região metropolitana do estado do Rio de Janeiro composta de treze municípios (Belford Roxo, Duque de Caxias, Guapimirim, Itaguaí, Japeri, Magé, Mesquita, Nilópolis, Nova Iguaçu, Paracambi, Queimados, São João de Meriti e Seropédica) que somam cerca de 3,7 milhões de habitantes – figura entre as regiões de menor IDH da região metropolitana do Rio de Janeiro, com profundas disparidades no acesso a um ensino público de qualidade [Souza 2022, Oliveira and Augusto 2025, Albuquerque 2021]. O FUNDEB é, desde 2007, o principal instrumento de financiamento da educação básica no Brasil, redistribuindo recursos vinculados aos impostos como ICMS, FPM, IPVA, de forma proporcional à quantidade de habitantes e geração de impostos do município. Um pressuposto comum quando se fala de políticas públicas é que mais recursos produzem, diretamente, melhores resultados de aprendizagem. Este projeto testa esse pressuposto empiricamente na Baixada Fluminense, articulando três perguntas de pesquisa: **(a)** o volume de repasses do FUNDEB se correlaciona com o desempenho no ENEM? **(b)** qual o papel das variáveis socioeconômicas nessa relação? **(c)** como se configura o acesso ao ensino superior via SISU para os egressos da região?

O restante deste artigo é organizado como o próprio projeto foi conduzido: a Seção 3 narra o caminho dos dados brutos até o dashboard final, detalhando engenharia de dados, análise estatística, modelagem preditiva e clusterização; a Seção 4 apresenta os resultados; e a Seção 5 responde às três perguntas de pesquisa e discute limitações.

2. Referencial Teórico

O debate sobre gasto público e qualidade do ensino remonta a [Hanushek 1986], que demonstrou que o gasto por aluno não é, isoladamente, preditor robusto de desempenho em testes padronizados – tese revisitada e reforçada em [Hanushek 2003]. No Brasil, [Soares and Alves 2013] e [Ferrão et al. 2022] mostram que renda familiar e escolaridade dos pais explicam a maior parte da variância interescolar nas notas do ENEM/SAEB, com o investimento público contribuindo de forma secundária. [Bourdieu 1986] fornece o arcabouço conceitual: capital econômico e cultural – não apenas o gasto nominal – estruturam trajetórias educacionais. Do lado metodológico, apoiamos-nos em [James et al. 2023] e [Géron 2022] para os algoritmos de aprendizado supervisionado e não supervisionado, e em [Bussab and Morettin 2024] para os testes estatísticos clássicos.

3. Metodologia: da Coleta de Dados ao Dashboard de Resultados

Para esse projeto optamos por apresentar um pipeline de dados de ponta a ponta, da ingestão de arquivos brutos até um produto interativo em que utilizamos para basear nossos resultados e conclusões – e esta seção o descreve na ordem em que foi construído.

3.1. Fontes e Volume de Dados

Utilizamos três bases de dados administrativas públicas que foram integradas para gerar o Dataset utilizado nesse trabalho: **microdados do ENEM** (INEP/MEC, 2013–2022) [INEP 2023], com escolas pertencentes aos treze municípios; **relatórios de repasses do FUNDEB** (FNDE, 2011–2024) [FNDE 2024], obrigatórios e voluntários; e **microdados do SISU** (MEC, 2014–2023) [MEC 2023], com candidato residente na região. Após filtragem de qualidade (remoção de treineiros e ausentes), o dataset individual do ENEM

totaliza 144.843 registros; o SISU acumula 1.319.290 inscrições e 40.846 matrículas; os repasses do FUNDEB somam mais de R\$ 14 bilhões em valores reais.

3.2. Engenharia de Dados: Desafios e Soluções

O maior esforço do projeto não foi analítico, mas de engenharia de dados: lidando com datasets pesados como, arquivos anuais do ENEM de até 3 GB, diferentes formatos distintos de planilha no FUNDEB ao longo da década e um dicionário de variáveis do INEP que mudou de nomenclatura entre edições. O pipeline, implementado em Python 3.10 com Polars e Pandas [McKinney 2023], resolveu isso com: (i) normalização Unicode NFD dos nomes municipais para reconciliar as três bases; (ii) detecção automática de cabeçalho nos CSVs do FNDE (estrutura diferente entre 2011–2014 e 2015–2024); (iii) deflacionamento dos valores do FUNDEB pelo IPCA a preços de dezembro de 2024; (iv) cálculo da nota objetiva como média das quatro provas do ENEM; e (v) *join* ENEM×FUNDEB pela chave município-ano, produzindo um dataset de modelagem com 50.110 observações. O resultado de cada etapa é persistido em Parquet (pasta *curated/*) e a linhagem completa é documentada em um grafo de proveniência W3C PROV (Figura 1), gerado automaticamente a partir dos próprios scripts do pipeline.




Figura 1. Grafo de proveniência (W3C PROV) do pipeline: da ingestão das três bases brutas à modelagem e ao dashboard.

3.3. Análise Estatística

Sobre os dados curados, calculamos estatísticas descritivas por município e aplicamos testes de hipótese (ANOVA e Kruskal-Wallis, $\alpha = 0,05$) para verificar se renda, tipo de escola e município discriminam o desempenho, além da correlação de Pearson e Spearman entre repasse FUNDEB, nota ENEM, escolaridade materna, renda e aprovação no SISU [Bussab and Morettin 2024].

3.4. Modelagem Preditiva

Para estimar o efeito marginal de cada preditor sobre a nota ENEM, treinamos, com divisão 80/20 e variáveis padronizadas (*StandardScaler*/*OneHotEncoder*): uma **Regressão Ridge** ($\lambda \sum \beta_j^2$), que produz coeficientes interpretáveis e estáveis mesmo com dummies categóricas correlacionadas; e um **Random Forest Regressor** (50 árvores, *max_depth*=10, selecionado por *GridSearchCV* 3-fold), cujas *feature importances* indicam a contribuição relativa de cada variável sem impor linearidade.

3.5. Clusterização Municipal

Para tipificar os treze municípios, aplicamos **K-Means** sobre nota média do ENEM, repasse médio anual do FUNDEB e taxa de aprovação no SISU, padronizados por `StandardScaler`. O número de clusters ($k = 3$) foi definido por inspeção do Método do Cotovelo e do Silhouette Score, complementada por critério de interpretabilidade regional – dado o $n = 13$ reduzido, esses índices não convergem para um ótimo global inequívoco. A visualização usa PCA em duas componentes.

3.6. Do Modelo ao Dashboard

Como etapa final do pipeline, os artefatos de modelagem (coeficientes, importâncias, rótulos de cluster) são exportados para CSV e consumidos por um dashboard interativo em Streamlit (pasta `dashboard/`), que expõe KPIs, séries temporais e os resultados desta seção sem exigir retreinamento a cada acesso – fechando o ciclo entre dado bruto e produto analítico reproduzível.

4. Resultados

Tabela 1. Estatísticas descritivas do ENEM por município (2013–2022). $\bar{x}$: média objetiva; σ : desvio-padrão.

Município	n	$\bar{x}$	σ
Paracambi	2.281	520,3	69,5
Nilópolis	9.401	510,8	67,7
Nova Iguaçu	33.536	503,7	64,5
Duque de Caxias	34.630	502,9	63,5
São João de Meriti	18.310	497,4	58,0
Belford Roxo	12.136	480,3	51,9
Japeri	2.658	477,4	52,7
Total (13 mun.)	144.843	498,5	63,1

A Tabela 1 (amostra dos extremos; os treze municípios estão no dashboard) mostra amplitude de 42,9 pontos entre o melhor (Paracambi) e o pior (Japeri) resultado médio, todos abaixo da média nacional do período (≈ 530 pontos). Testes ANOVA e Kruskal-Wallis confirmam que renda familiar ($F = 972,8$), tipo de escola ($F = 3.690,3$) e município ($F = 251,1$) discriminam significativamente o desempenho ($p < 0,001$ em todos os casos).

A Figura 2 sintetiza o achado central: a correlação FUNDEB $\times$ Nota Objetiva ($r = 0,41$) é amplamente explicada por variáveis de confusão – municípios maiores recebem mais recursos e têm maior diversidade socioeconômica. No nível individual (regressão com 50.110 observações), o coeficiente do repasse é estatisticamente significativo ($p < 0,001$) mas praticamente nulo ($\approx 8,5 \times 10^{-9}$ pontos por real, ou menos de 1 ponto para R\$ 100 milhões adicionais), pois o FUNDEB financia toda a educação básica municipal, não apenas os candidatos ao ENEM. As correlações FUNDEB $\times$ Escolaridade Materna ($r = 0,80$) e FUNDEB $\times$ Renda ($r = 0,42$) confirmam porte municipal e composição social como as variáveis de confusão dominantes.

Dados Socioeconômicos x FUNDEB x ENEM x SISU




Figura 2. Correlação de Pearson entre repasse FUNDEB, notas do ENEM, escolaridade materna, renda e aprovação no SISU (nível municipal-anual).

O Random Forest (Figura 3) confirma a hierarquia da Ridge: renda familiar e escolaridade materna lideram a importância preditiva, seguidas do município e do tipo de rede; o repasse FUNDEB tem a menor importância relativa entre todos os preditores. Na Ridge, rede Federal (+40 a +55 pontos sobre a Estadual) e rede Privada (+25 a +35 pontos) são os maiores coeficientes positivos isolados.

Tabela 2. Perfil médio dos três clusters municipais (K-Means, $k = 3$).

Cluster	Nota ENEM	Repasso Médio/Mun.	Taxa SISU
Eficiência Relativa (6 mun.)	496,0	R\$ 156,6 Mi	29,5%
Paradoxo do Repasse (3 mun.)	493,7	R\$ 493,1 Mi	27,3%
Vulnerabilidade Estrutural (4 mun.)	475,7	R\$ 123,1 Mi	20,5%

A Tabela 2 e a Figura 4 revelam três tipologias (Silhouette $\approx 0,42$): municípios com **eficiência relativa** (Mesquita, Nilópolis, Nova Iguaçu, Paracambi, São João de Meriti, Seropédica) atingem a melhor nota com investimento moderado, beneficiados pela vizinhança acadêmica (ex.: UFRRJ); o **paradoxo do repasse** (Duque de Caxias, Guapimirim, Itaguaí) recebe o maior volume de recursos da região mas obtém resultado apenas mediano; e a **vulnerabilidade estrutural** (Belford Roxo, Japeri, Magé, Queimados) combina o pior desempenho com repasse intermediário, evidenciando ineficiência alocativa.




Figura 3. Feature importances do Random Forest Regressor ($R^2 = 0,24$, RMSE $\approx$ 53 pts).

Quanto ao acesso ao ensino superior, a taxa bruta de aprovação no SISU é de apenas 2,84% (40.846 de 1.319.290 inscrições, 2013–2023), homogênea entre municípios (2,18%–3,59%) e concentrada em licenciaturas e cursos de demanda moderada (Pedagogia, Química, Administração), com baixíssima procura em Exatas de alta competição – consistente com o perfil de notas majoritariamente abaixo de 540 pontos.

5. Conclusão

(a) Financiamento vs. desempenho: o repasse do FUNDEB tem efeito estatisticamente significativo mas praticamente irrelevante sobre a nota individual do ENEM ($\approx 8,5 \times 10^{-9}$ pts/R\$, $R^2 = 0,24$), em parte por um descasamento institucional – o FUNDEB financia toda a educação básica municipal, enquanto o ENEM avalia o concluinte do ensino médio, majoritariamente estadual. **(b) Mediação socioeconômica:** renda familiar, escolaridade materna e tipo de rede explicam a maior parte da variância predizível, e a clusterização revela três tipologias regionais de (in)eficiência alocativa. **(c) Acesso via SISU:** o ingresso no ensino superior público é estruturalmente limitado (2,84%) e concentrado em carreiras de menor competitividade, refletindo restrições de desempenho mais do que escolha vocacional.

O projeto – da ingestão de microdados brutos ao dashboard público – sustenta uma conclusão de política pública: enfrentar a desigualdade educacional na Baixada Fluminense exige políticas de gestão escolar e de equidade socioeconômica, não apenas o aumento nominal de repasses. **Limitações:** a análise é correlacional (estimativas causais exigiriam desenhos quase-experimentais); o $n = 13$ municípios limita a robustez




Figura 4. Projeção PCA dos três clusters municipais.

das partições (agenda futura: Ward Linkage e DBSCAN); e o recorte regional impede generalização imediata a outros estados.

Disponibilidade

Código, dados curados, modelos e dashboard estão publicados em <https://github.com/mendesvlt/analise-investimento-enem-sisu-baixada-fluminense>, sob licença MIT.

Referências

- Albuquerque, E. A. A. (2021). Baixada fluminense, uma periferia por excelência. *Geografia (Londrina)*, 30(1):63.
- Bourdieu, P. (1986). The forms of capital. In Richardson, J. G., editor, *Handbook of Theory and Research for the Sociology of Education*, pages 241–258. Greenwood Press, New York.
- Bussab, W. O. and Morettin, P. A. (2024). *Estatística Básica*. SaraivaUni, São Paulo, 10 edition.
- Ferrão, M. E., Santos, A., and Nata, G. (2022). Estratificação socioeconômica e desempenho no ENEM: uma análise multinível. *Estudos em Avaliação Educacional*, 33:e07753.
- FNDE (2024). Relatórios de repasses do FUNDEB aos municípios – 2011–2024. Technical report, Fundo Nacional de Desenvolvimento da Educação, Brasília, DF. Disponível em: <https://www.fnde.gov.br>.
- Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and Tensor-Flow*. O'Reilly Media, Sebastopol, CA, 3 edition.
- Hanushek, E. A. (1986). The economics of schooling: Production and efficiency in public schools. *Journal of Economic Literature*, 24(3):1141–1177.
- Hanushek, E. A. (2003). The failure of input-based schooling policies. *The Economic Journal*, 113(485):F64–F98.
- INEP (2023). Microdados do exame nacional do ensino médio – ENEM 2013–2022. Technical report, Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira, Brasília, DF. Disponível em: <https://www.gov.br/inep>.
- James, G., Witten, D., Hastie, T., and Tibshirani, R. (2023). *An Introduction to Statistical Learning*. Springer, New York, 2 edition.
- McKinney, W. (2023). *Python para Análise de Dados*. Novatec Editora, 3 edition.
- MEC (2023). Microdados do sistema de seleção unificada – SISU 2014–2023. Technical report, Ministério da Educação, Brasília, DF. Disponível em: <https://www.gov.br/inep>.
- Oliveira, A. L. R. and Augusto, E. C. B. S. (2025). Desempenho em matemática e desigualdades: Fatores para (re)pensar uma educação equitativa. *Revista Inter-Ação*, 49(3):1551–1565.
- Soares, J. F. and Alves, M. T. G. (2013). Efeitos de escolas e municípios na qualidade do ensino fundamental brasileiro. *Cadernos de Pesquisa*, 43(149):492–517.
- Souza, F. A. (2022). O financiamento da educação das prefeituras da região da baixada litorânea fluminense na pandemia. *Revista Brasileira de Política e Administração da Educação*, 38(1):1–20.